CIPHERMARK

Developpement d'un systeme de tatouage numerique securise pour les modeles generatifs, fonde sur la technique OTP

Un temoin cryptographique unique par generation, inscrit dans les poids du modele

Presente par

NGUEAGHO TIODONG Roberto Landry

Master 2 · Informatique

Sous la direction de

Pr Aminou HALIDOU

Universite de Yaounde I · Faculte des Sciences

Departement d'Informatique · Master 2 · Annee 2025-2026

LE CONSTAT

Une image generee ne se distingue plus d'une photo

- **Le contenu synthetique est devenu indiscernable** a l'oeil comme aux detecteurs statistiques.
- **Prouver l'origine d'une image** devient une exigence reglementaire : l'AI Act impose le marquage des contenus generes.
- **Un filigrane ne suffit pas.** Il doit resister aux transformations ordinaires, et surtout ne jamais accuser a tort.

17
articles publies
en 2024-2026

0
combinant les trois
proprietes visees

Les trois proprietes

- securite cryptographique formelle
- tracabilite individuelle par generation
- couverture architecturale large

Le verrou n'est pas la detection : c'est la preuve, individuelle et opposable.

SYNTHESE CRITIQUE

Ce que fait l'existant, et ce qui lui manque

Approche	Securite formelle	Message unique	Familles couvertes
DistSeal (2026)	non	non : message fixe, rejouable	diffusion + autoregressif
WOUAF (2024)	non	oui, mais code arbitraire	diffusion
MetaSeal (2026)	oui	oui	diffusion seule
CipherMark	oui	oui, lie au contenu	diffusion + autoregressif

Le manque, precisement

DistSeal grave un message FIXE dans les poids du decodeur : toutes ses generations portent le meme filigrane, qui peut donc etre rejoue. Les schemas cryptographiques, eux, restent confines a la diffusion. Aucun travail ne tient les trois proprietes ensemble.

QUESTION DE RECHERCHE

Peut-on concevoir, pour les modeles generatifs, un tatouage garantissant a la fois une securite cryptographique formelle, une tracabilite individuelle par generation et une compatibilite architecturale large ?

Reponse apportee : oui, sous conditions explicites, et le modele generatif peut porter le dispositif lui-meme.

LA PROPOSITION

Le champ temoin Ω : une signature par generation

$$\Omega = \mathrm{HMAC}(K_{secret}, h) \oplus \mathrm{PRG}(s_{master}, nonce)$$

HMAC(K, h)

lie le temoin au CONTENU par une empreinte perceptuelle DINOv2.

Transplanter la marque sur une autre image la casse.

⊕ PRG(s, nonce)

rend chaque generation UNIQUE et illisible sans les cles.

Rejouer une marque observee devient impossible.

Cle par createur

k_user = HKDF(k_master, identifiant).

L'attribution devient infalsifiable, non declarative.

Ce que DistSeal grave une fois pour toutes, CipherMark le recalcule a chaque image.

ARCHITECTURE

Trois couches, et une base de tracabilite

EMISSION

Le generateur produit le latent. Le decodeur, module par Ω, rend une image DEJA tatouee.

TRACABILITE

Une entree par generation : nonce, empreinte de reference, createur. Aucun secret par utilisateur n'est stocke.

VERIFICATION

L'extracteur relit Ω, le registre donne le createur, sa cle est REDERIVEE, le verdict tombe.

Le verifieur ne connait rien a l'avance : il lit le nonce, consulte le registre, et rederive la cle du createur enregistre.

LE MECANISME, HERITE DE WOUAF

Ω module les poids du decodeur : le tatouage naît avec l'image

$$\text{activation} \leftarrow \text{activation} \odot (1 + \gamma(\Omega)) + \beta(\Omega)$$

- **Identite exacte a l'initialisation :** les tetes γ et β sont initialisees a zero, donc le decodeur conditionne demarre identique au decodeur d'origine.
- **Modulation bornee** ($\gamma \leq 0{,}3$; $\beta \leq 0{,}1$), la ou WOUAF demodule. La degradation devient impossible au-dela d'un seuil connu.
- **Ω change a chaque generation** sans reentrainer le modele : c'est ce que le message fixe de DistSeal interdisait.

6
etages modules (DC-AE)

3
etages modules (MaskGIT)

Cet ecart de prises explique a lui seul la difference de robustesse entre les deux familles.

METHODOLOGIE

Ce qui a ete mesure, et comment

3
canaux d'inscription
evalues separement

20
conditions : 19 attaques
+ la reference

5 000
images par canal,
jamais vues a l'entrainement

300 000
verifications
au total

Les vingt conditions du protocole de DistSeal

JPEG Q = 90, 70, 50, 30 · flou gaussien k = 3, 5, 7 · reechantillonnage 0,75 et 0,5 · recadrage 90, 70, 50 % · luminosite et contraste x0,8 et x1,2 · bruit σ = 0,02, 0,05, 0,10

Parametres FIXES et non tires au hasard : les chiffres sont reproductibles d'une execution a l'autre. Deux controles negatifs accompagnent chaque mesure.

Meme protocole, memes parametres, meme echelle pour les trois canaux : c'est ce qui rend la comparaison possible.

Le couple embedder / extracteur en espace pixel

Condition	Verdicts	Bits relus
Sans attaque	99.8 %	0.9995
JPEG Q = 30	95.8 %	0.9991
Bruit σ = 0,1	86.6 %	0.9973
Flou k = 7	70.7 %	0.9193
Recadrage 90 %	0 %	0.6105

22,5 dB
PSNR du filigrane

0,942
SSIM

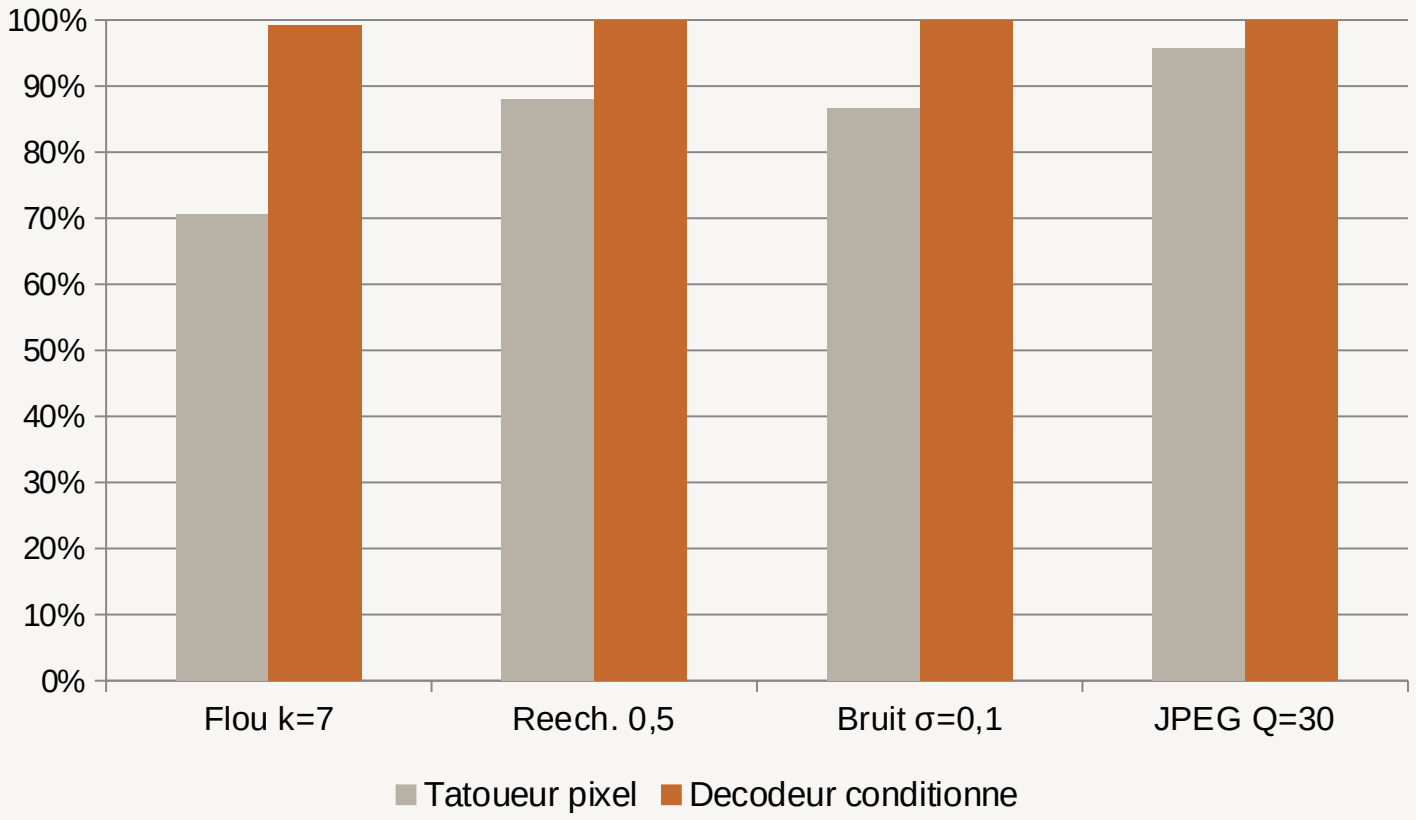
Ce qu'il faut retenir

Compression, photometrie et bruit ne genent pas. Le flou et le reechantillonnage degradent progressivement.

Le recadrage annule le canal : Ω est un message GLOBAL de 64 bits reparti sur toute l'image, non un motif repete localement.

RESULTAT 2 SUR 4 · LE PLUS INATTENDU

Le decodeur conditionne resiste mieux que le tatouage post-hoc



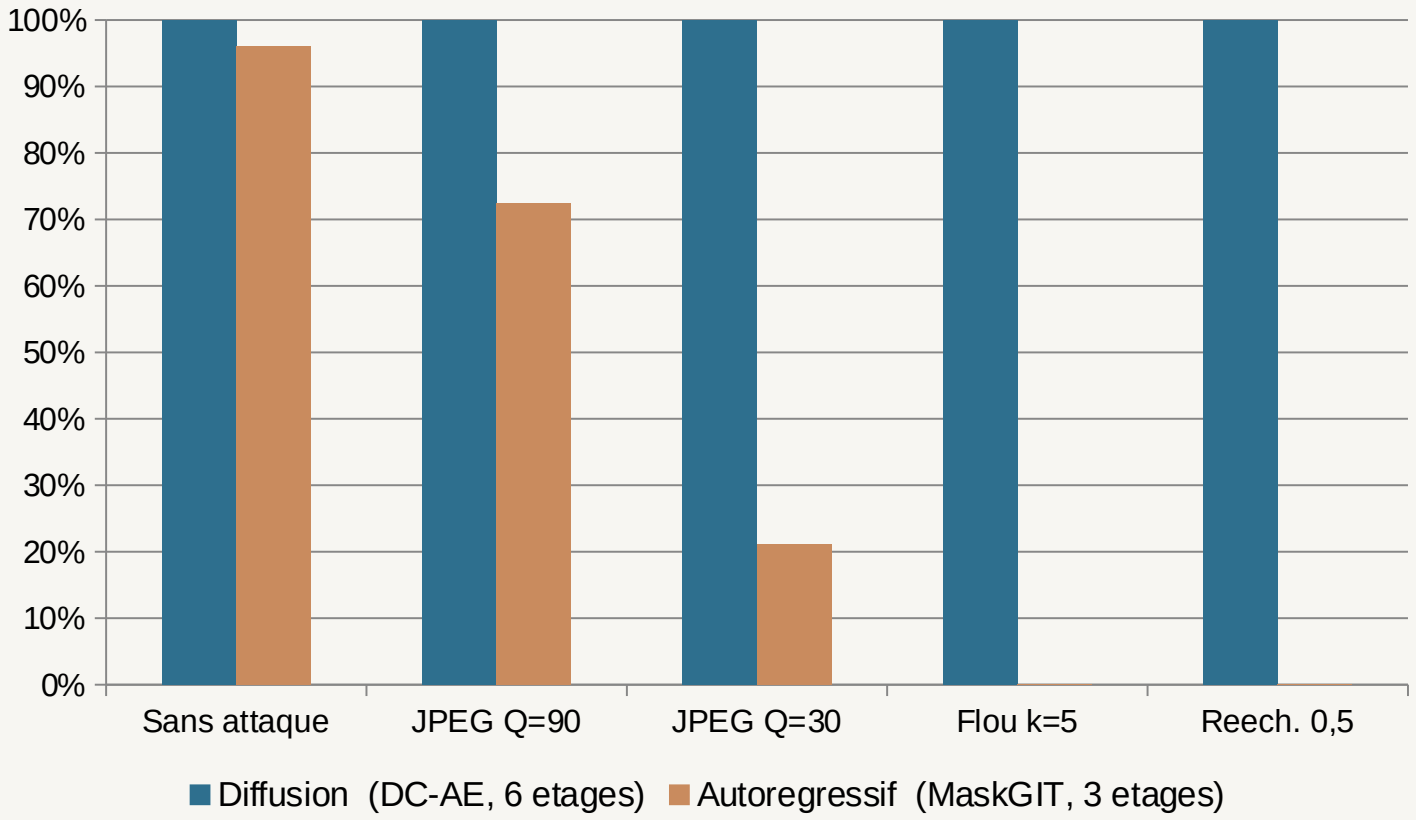
Pourquoi

Le temoin porte par les poids NAIT avec l'image, au lieu de s'y superposer apres coup.

Il est donc reparti dans la structure meme du contenu genere, et non dans un residu que le filtrage efface.

Ce n'etait pas acquis d'avance : c'est le resultat le plus fort de la campagne.

Le meme mecanisme, deux architectures, deux resultats



Le cout de l'agnosticisme

Le conditionneur ne trouve que 3 etages modulables dans MaskGIT contre 6 dans le DC-AE, et l'un des trois porte sur la sortie RGB, ou moduler revient a teinter l'image.

0,48 M de parametres contre 2,91 M.

Le mecanisme s'applique partout ; son efficacite depend des prises que le decodeur offre.

RESULTAT 4 SUR 4

Ce que la cryptographie apporte, et que la mesure confirme

0 / 25 000	0 / 300	0,10 %	100 / 100
fausse attribution	rejeu reussi	transplantation reussie (8/8 avant correctif)	chaine complete protocole reel

La chaine de bout en bout, verifiee sur GPU

Une classe est fournie. Le modele genere. L'image sort tatouee d'un Ω derive de l'IDENTITE du createur et lie au contenu. Un verifieur qui ne sait rien a l'avance lit le nonce, consulte le registre, rederive la cle, et retrouve le nom.

Controle negatif : decoder le MEME latent SANS conditionnement donne 31/64 bits, le hasard, et zero verdict sur 300. Le temoin vient bien de la modulation.

ANALYSE COMPARATIVE

Ce que CipherMark ajoute, et ce qu'il concede

	DistSeal (2026)	CipherMark
Message par generation	fixe, rejouable	unique, lie au contenu
Securite formelle	aucune	HMAC-SHA256 + ChaCha20
Attribution au createur	non	cle derivee, 0 erreur / 25 000
Compression et bruit	99,23 % (bit acc.)	100 % de verdicts
Transformations geometriques	91,62 %	0 %
Familles couvertes	diffusion + autoregressif	les deux, avec un ecart mesure

Un echange explicite

Sur les transformations non geometriques, CipherMark tient son rang et depasse DistSeal en compression. Sur la geometrie, le retrait est une falaise. En contrepartie il acquiert quatre proprietes absentes de DistSeal.

DISCUSSION

Trois limites, annoncees plutot que decouvertes apres coup

Le recadrage annule le canal

0 % de verdicts sur les trois voies d'inscription. Ω est un message global de 64 bits, non un motif repete localement. La limite est structurelle, pas un defaut d'entrainement.

La liaison au contenu est plus fragile que le temoin

Sous JPEG Q=30, 6 % des empreintes survivent quand 96 % des verdicts tiennent. Une verification exigeant EN PLUS l'empreinte serait bien moins robuste.

Le couple entierement latent n'a pas abouti

Seul volet du programme reste inacheve. Obstacle diagnostique, correctif mesure, convergence non atteinte.

Sous transformation passive, le systeme ne produit que des faux negatifs, jamais de fausses accusations : le profil recherche en forensique.

PERSPECTIVES

Ce qui prolonge ce travail

- **Achever le couple latent.** L'obstacle est diagnostique : la recette de DistSeal, dont le poids de fidelite est nul, produit un modele qui lit bien en detruisant l'image. Retablir ce poids inverse la tendance des les premieres epoques.

- **Un hachage invariant a la geometrie** mais discriminant entre contenus : c'est a soi seul un sujet de these, et la reponse a la falaise du recadrage.

- **Consolider le seuil de comparaison,** aujourd'hui calibre sur un perimetre restreint et adosse a une binarisation instable sous compression.

- **Une application industrielle.** L'AI Act cree une demande pour des systemes prouvant l'origine sans fausse accusation : c'est exactement le profil d'erreurs de CipherMark.

CONCLUSION

Trois contributions, et une reponse

CONCEPTUELLE

Le champ temoin Ω comble un vide reel : unique par generation, lie au contenu, illisible sans les cles.

EXPERIMENTALE

La chaine fonctionne de bout en bout, et l'inscription par modulation des poids surpasse le tatouage post-hoc.

ANALYTIQUE

Un mur de capacite apparent s'est revele un point stationnaire exact ; deux hyperparametres ont porte la precision a 0,9998.

Le tatouage generatif peut devenir une preuve cryptographique, individuelle et liee au contenu, aux limites connues.

Merci de votre attention

NGUEAGHO TIODONG Roberto Landry

Universite de Yaounde I · Faculte des Sciences

Code et resultats : github.com/ngueagho/distseal-meta